Рубежный контроль №1

Утробин Егор Эдуардович, ИУ5-61Б, Вариант 19. Задание 3.

Задача №3.

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

Дополнение для ИУ5-61Б

Для пары произвольных колонок данных построить график "Диаграмма рассеяния".

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import *
```

Датасет

In [2]:
```
data = pd.read_csv('marvel-wikia-data.csv', sep=",")
```

In [3]:
```
# первые строки
data.head()
```

Out[3]:

	page_id	name	urlslug	ID	ALIGN	EYE	HAIR	
0	1678	Spider-Man (Peter Parker)	\/Spider-Man_(Peter_Parker)	Secret Identity	Good Characters	Hazel Eyes	Brown Hair	C
1	7139	Captain America (Steven Rogers)	\/Captain_America_(Steven_Rogers)	Public Identity	Good Characters	Blue Eyes	White Hair	C
2	64786	Wolverine (James \"Logan\" Howlett)	\/Wolverine_(James_%22Logan%22_Howlett)	Public Identity	Neutral Characters	Blue Eyes	Black Hair	C
3	1868	Iron Man (Anthony \"Tony\" Stark)	\/Iron_Man_(Anthony_%22Tony%22_Stark)	Public Identity	Good Characters	Blue Eyes	Black Hair	C
4	2460	Thor (Thor Odinson)	\/Thor_(Thor_Odinson)	No Dual Identity	Good Characters	Blue Eyes	Blond Hair	C

In [4]:
```
# типы колонок
```

```
data.dtypes
```

Out[4]:
```
page_id              int64
name                object
urlslug             object
ID                  object
ALIGN               object
EYE                 object
HAIR                object
SEX                 object
GSM                 object
ALIVE               object
APPEARANCES        float64
FIRST APPEARANCE    object
Year               float64
dtype: object
```

Масштабирование

In [5]:
```
# Статистика датасета
data.describe()
```

Out[5]:

	page_id	APPEARANCES	Year
count	16376.000000	15280.000000	15561.000000
mean	300232.082377	17.033377	1984.951803
std	253460.403399	96.372959	19.663571
min	1025.000000	1.000000	1939.000000
25%	28309.500000	1.000000	1974.000000
50%	282578.000000	3.000000	1990.000000
75%	509077.000000	8.000000	2000.000000
max	755278.000000	4043.000000	2013.000000

Масштабирование на основе MinMax - значения лежат в диапазоне от 0 до 1

In [6]:
```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['APPEARANCES']])
plt.hist(sc1_data, 50)
plt.title("MinMax масштабирование")
plt.show()
```

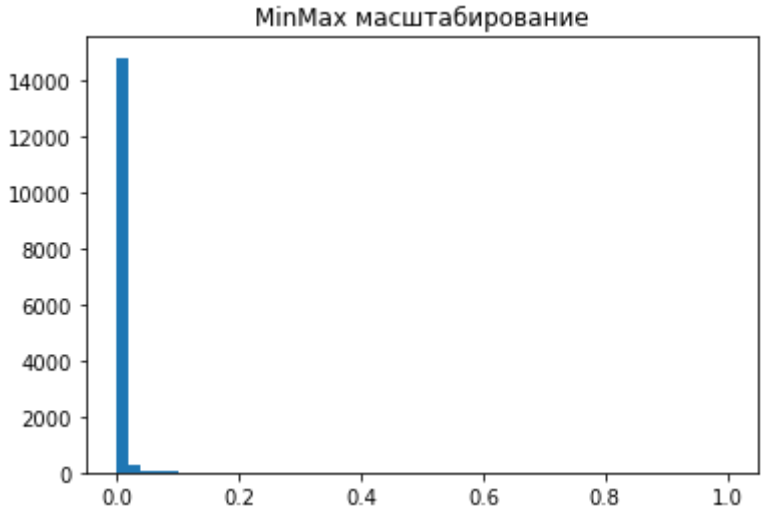

Z оценка - значения лежат в диапазоне от -3 до 3

In [7]:
```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['APPEARANCES']])
plt.hist(sc2_data, 50)
plt.title("Масштабирование на основе Z оценки")
plt.show()
```

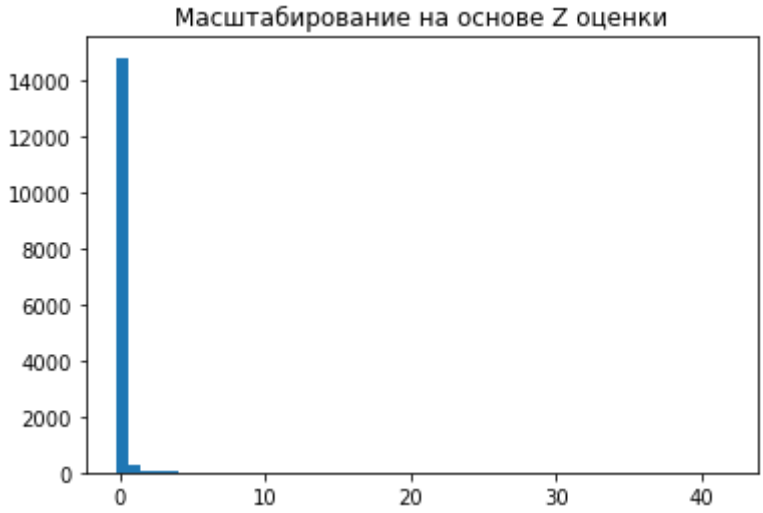

Преобразование категориальных признаков в количественные

Label encoding

In [8]:
```
# обработка пропусков с заменой на "Unknown"
imp2 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='Unknown
data['EYE'] = imp2.fit_transform(data[['EYE']])

#Уникальные типы
types = data['EYE']
types.unique()
```

Out[8]:
```
array(['Hazel Eyes', 'Blue Eyes', 'Brown Eyes', 'Green Eyes', 'Grey Eyes',
       'Yellow Eyes', 'Gold Eyes', 'Red Eyes', 'Black Eyeballs',
       'Amber Eyes', 'Variable Eyes', 'Unknown', 'Black Eyes',
       'White Eyes', 'Orange Eyes', 'Silver Eyes', 'Purple Eyes',
       'Pink Eyes', 'One Eye', 'Violet Eyes', 'Multiple Eyes',
       'Magenta Eyes', 'Yellow Eyeballs', 'No Eyes', 'Compound Eyes'],
      dtype=object)
```

In [9]:
```
#Label encoding
le = LabelEncoder()
data_le = le.fit_transform(types)
```

Результат

In [10]:
```
np.unique(data_le)
```

Out[10]:
```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
       17, 18, 19, 20, 21, 22, 23, 24])
```

Обратное преобразование

In [11]:
```
le.inverse_transform(data_le)
```

Out[11]:
```
array(['Hazel Eyes', 'Blue Eyes', 'Blue Eyes', ..., 'Black Eyes',
       'Unknown', 'Unknown'], dtype=object)
```

One hot encoding

In [12]:
```
pd.get_dummies(data['EYE']).head()
```

Out[12]:

	Amber Eyes	Black Eyeballs	Black Eyes	Blue Eyes	Brown Eyes	Compound Eyes	Gold Eyes	Green Eyes	Grey Eyes	Hazel Eyes	...	Pink Eyes	Purple Eyes
0	0	0	0	0	0	0	0	0	0	1	...	0	0
1	0	0	0	1	0	0	0	0	0	0	...	0	0
2	0	0	0	1	0	0	0	0	0	0	...	0	0
3	0	0	0	1	0	0	0	0	0	0	...	0	0
4	0	0	0	1	0	0	0	0	0	0	...	0	0

5 rows × 25 columns

In [13]:
```
sns.jointplot(x = "page_id", y = "APPEARANCES", kind="scatter", data = data)
```

Out[13]:
```
<seaborn.axisgrid.JointGrid at 0x2736fa93ca0>
```

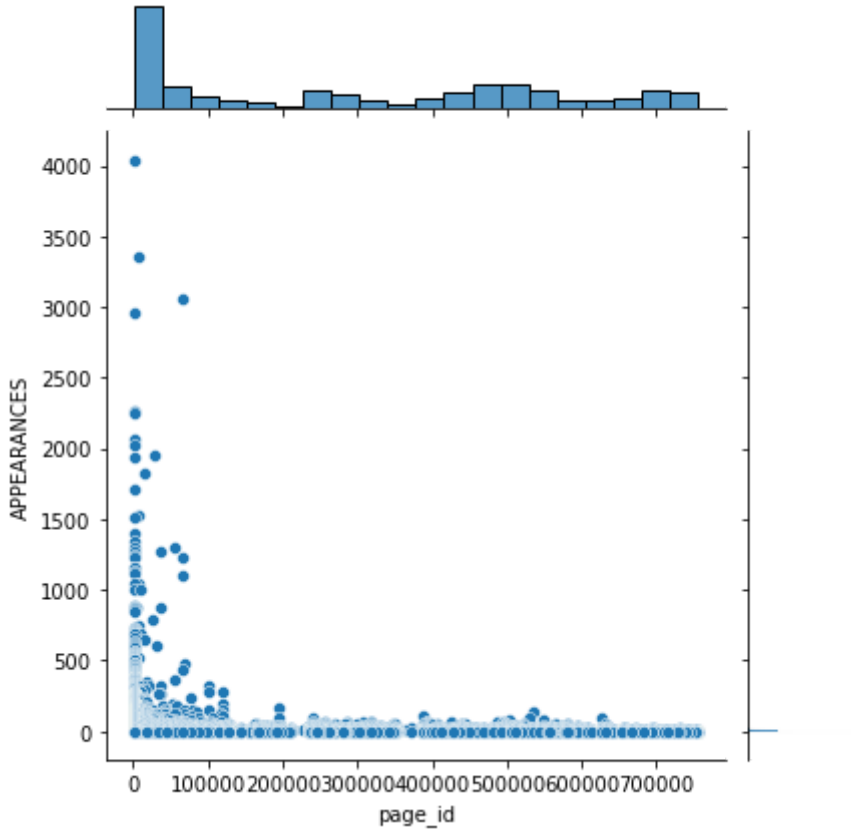

In [14]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='page_id', y='APPEARANCES', data=data, hue='Year')
```

Out[14]:
```
<AxesSubplot:xlabel='page_id', ylabel='APPEARANCES'>
```

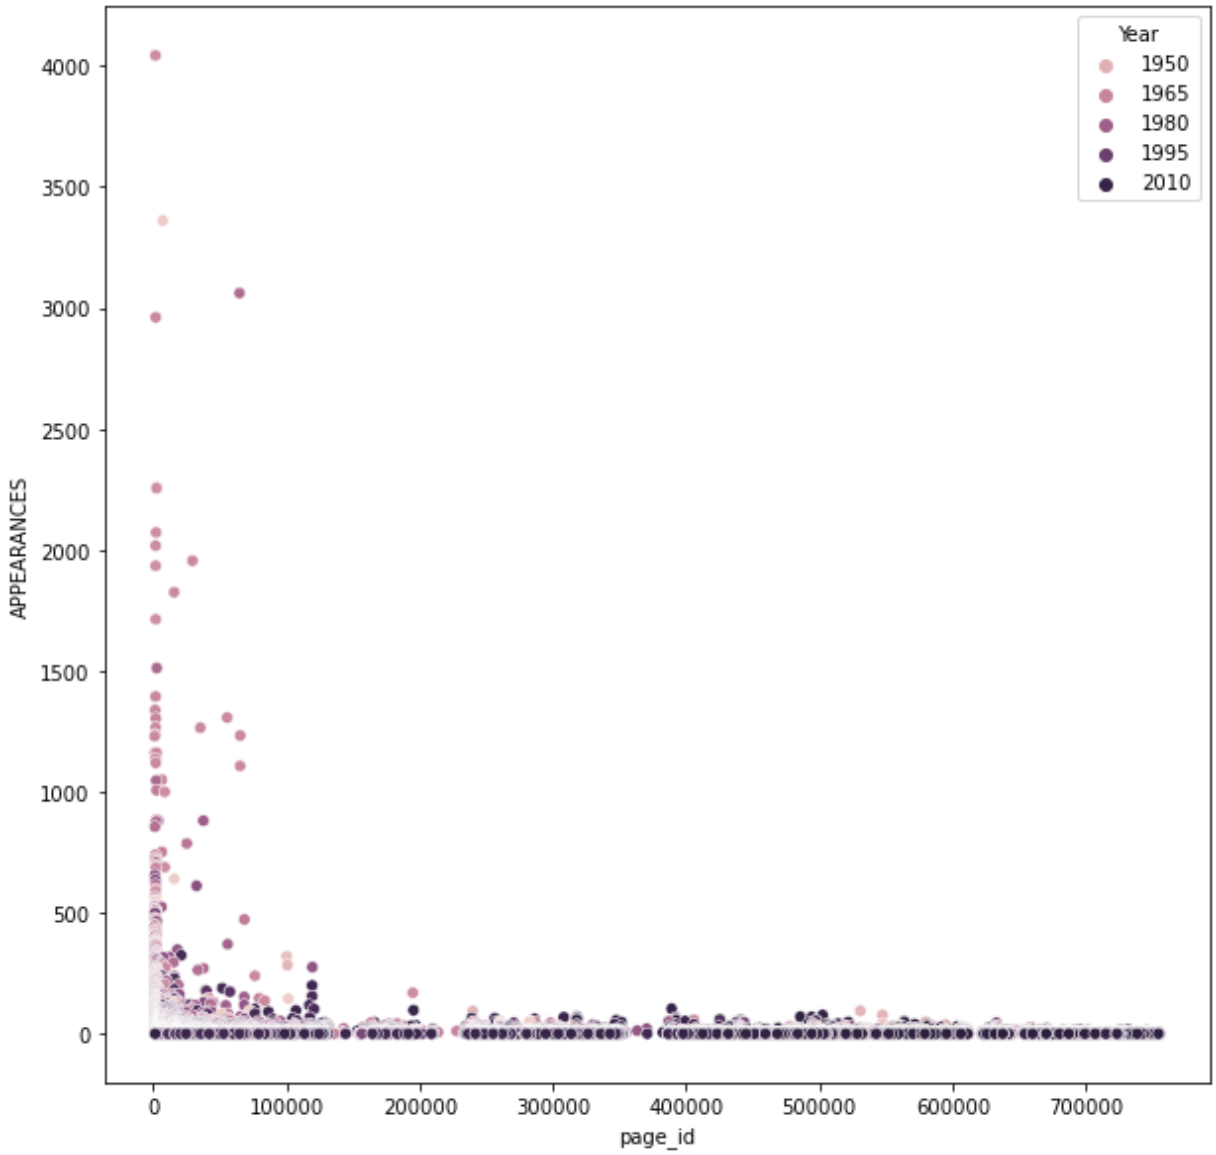
Year
1950
1965
1980
1995
2010
APPEARANCES
4000
3500
3000
2500
2000
1500
1000
500
0
0
100000
200000
300000
400000
500000
600000
700000
page_id

In [ ]: